

Gewachsen, nicht gefertigt

Kapitel 2

Szene: Ein Mann und eine Frau sitzen tagsüber in einem Restaurant. Die Stimme der Frau ist leise und eindringlich.

FRAU: Und das Problem ist, ich kann mit niemandem ein vernünftiges Gespräch darüber führen. Alle in seiner Familie außer ihm sind schreckliche Menschen, und er sagt, er müsse hart daran arbeiten, nicht selbst schrecklich zu sein, und manchmal *ist* er schrecklich, auch zu mir. Auf meiner Seite kämpft meine Familie mit Depressionen. Und meine Eltern liegen mir in den Ohren, ein Kind zu bekommen, und meine Freunde haben tausend Meinungen, die auf nichts zu beruhen scheinen außer ihren eigenen Erfahrungen mit ihren eigenen Partnern und Kindern. Soll ich nach einem Samenspender suchen? Soll ich es ganz aufgeben, Kinder zu bekommen? Und wenn ich ein Kind bekomme, wird es glücklich und gütig aufwachsen?

MANN: Da sind Sie bei mir genau richtig! Niemand kann besser vorhersagen, was aus einem Baby wird, als ich! Ich weiß alles darüber, wie Babys gemacht werden!

FRAU: Sie... was? Ich muss nicht wissen, wie Babys gemacht werden! Ich muss wissen, was aus meinem Baby wird!

MANN: Nun, wenn Sie wissen, wie Babys *gemacht* werden... was könnten Sie dann sonst noch wissen müssen?

FRAU: Mein erster Gedanke war: „die tatsächliche Genetik meines Babys“, nur—

MANN: Ah! Dann habe ich die Lösung! Die Sequenzierung des gesamten Genoms ist heutzutage durchaus erschwinglich. Erzeugen Sie einfach einen Embryo aus einer Ihrer Eizellen und dem Samen Ihres Mannes und lassen Sie das Genom sequenzieren, bevor Sie entscheiden, ob Sie ihn einsetzen lassen. Diese Gensequenz wird Ihnen alles sagen, was es über Ihr Baby zu wissen gibt.

FRAU: Aber wissen wir genug über Gene, die mit Dingen wie „ein schrecklicher Mensch sein“ oder „glücklich sein“ zusammenhängen? Genug, um mir zu sagen—

MANN: Sobald Sie alle DNA-Basen in den Genen Ihres Babys kennen und sie jederzeit nachschlagen können, wird Ihnen die Genetik Ihres Babys vollkommen transparent sein. Es wird keine Wahrheit über seine Gene geben, die Sie nicht kennen.

FRAU: Ich bekäme eine Datei mit drei Milliarden unergründlichen Buchstaben wie „CATTCA“. Es würde mich hundert Jahre kosten, sie alle zu lesen. Ich würde nichts lernen, selbst wenn ich es versuchte. Selbst wenn diese Milliarden unergründlicher Buchstaben einen enormen Einfluss auf das Schicksal meines Babys haben, sagen mir rohe DNA-Buchstaben nicht wirklich, wie das Gehirn meines Kindes funktioniert, welche Gedanken in diesem Gehirn ablaufen werden, wenn mein Kind erwachsen ist...

MANN: Oh, Sie meinen, Sie kennen sich nicht mit Physik aus! Aber das ist ganz einfach! Sobald Sie wissen, wie Protonen und Neutronen und Elektronen miteinander wechselwirken, wissen Sie alles, was es über Gehirne zu wissen gibt, denn Sie verstehen dann jedes Ereignis, das in den Neuronen abläuft.

FRAU: Lassen Sie uns das Thema wechseln.

BEVOR WIR ERKLÄREN KÖNNEN, WARUM eine künstliche Superintelligenz, die mit irgendetwas Ähnlichem wie den heutigen Methoden geschaffen wird, zwangsläufig schiefgehen würde, müssen wir einen kurzen Überblick über diese heutigen Methoden geben: wie sie funktionieren, was sie hervorbringen und was KI-Ingenieure mit einer Mutter gemeinsam haben, die nur die DNA ihres Babys kennt.

Die grundlegendste Tatsache über heutige KIs ist, dass sie *gewachsen, nicht gefertigt* sind. Es ist nicht wie bei der Entstehung anderer Software—tatsächlich ähnelt es eher der Art, wie ein Mensch entsteht, zumindest in einigen wichtigen Punkten. Nämlich: Die Ingenieure verstehen den Prozess, der zu einer KI führt, aber sie verstehen nicht besonders gut, was in den KI-Gehirnen vor sich geht, die zu erschaffen ihnen gelingt.

Angenommen, ein Ingenieur ohne tiefes Verständnis von Sprache oder eine große Theorie der Intelligenz möchte eine Maschine bauen, die sinnvoll spricht. Wie könnte er vorgehen?

Er möchte einen Text vorgeben und eine Maschine diesen Text auf sinnvolle Weise weiter-schreiben lassen.

Er beschließt, ihr zunächst beizubringen, dass in einem Satz, der mit **Es war einmal ei** beginnt, der nächste Buchstabe wahrscheinlich „n“ ist.

Er *könnte* ein Programm schreiben, das einfach prüft, ob das Satzfragment **Es war einmal ei** lautet, und dann den Buchstaben **n** ausgibt. Aber das würde bei anderen Satzfragmenten wie **Im Anfang war das Wor** nicht funktionieren, und er möchte, dass die Maschine gut darin ist, allerlei Sätze zu vervollständigen, ja, Gespräche oder Aufsätze zu erzeugen. Sie soll sogar Sätze sinnvoll vervollständigen, die noch nie ein Mensch getippt hat.

Wenn er moderne KI-Methoden verwendet, geht es als Nächstes ungefähr so weiter:

1. Zuerst nimmt er das Satzfragment—**Es war einmal ei** in unserem Beispiel—und wandelt es in eine Zahlenreihe um, indem er etwa A mit 1, B mit 2, C mit 3 und so weiter verknüpft, plus ein paar Zahlen für Leerzeichen und Satzzeichen. **Es war einmal ei** wird zu einer Zahlenfolge wie 5 19... Das nennt man die **Eingabe**.
2. Als Nächstes besorgt er sich einen Computer, der Ummengen von Zahlen speichern kann. Jeder Speicherplatz für eine Zahl heißt **Parameter**. (Stand Anfang 2025 verwenden modernste KIs einige Billionen Parameter.)
3. Er füllt diesen Speicher mit Zahlen; stark vereinfacht gesagt, nehmen wir an, diese Zahlen werden zufällig gewählt. Die Zahlen in den Speicherplätzen heißen **Gewichte**.
4. Dann legt er die **Architektur** fest: die Regeln dafür, wie seine Eingabe (etwa die Folge 5 19... von **Es war einmal ei**) mit den Gewichten in den Parametern kombiniert wird. Etwa so: „Ich multipliziere jede Eingabezahl mit dem Gewicht im ersten Parameter, addiere dann das Gewicht im zweiten Parameter hinzu, ersetze das Ganze durch null, falls es negativ ist, und dann...“ Er wählt viele solcher Operationen—Hunderte Milliarden—und bindet so jedes einzelne Gewicht in die Berechnung ein.
5. All diese Operationen spucken eine Reihe von **Ausgabe**zahlen aus, die er als Vorhersage darüber deutet, welcher Buchstabe als Nächstes kommt. In unserem Beispiel würde er die erste Ausgabezahl als Wahrscheinlichkeit für A behandeln, die zweite Ausgabezahl als Wahrscheinlichkeit für B und so weiter.
6. Als Nächstes „trainiert“ er seine heranwachsende Maschinenintelligenz mit einem Verfahren namens **Gradientenabstieg**.

Da die anfänglichen Gewichte zufällig sind, spuckt das Programm beim ersten Durchlauf Unsinn aus. Vielleicht sagt es, dass der Buchstabe **b** mit 65 Prozent Wahrscheinlichkeit als Nächstes kommt und der Buchstabe **n** nur mit 1 Prozent.

Aber jetzt kommt der Clou: Wenn er die Architektur genau richtig gewählt hat, kann er berechnen, welche Rolle jeder einzelne Parameter bei der Bestimmung des Endergebnisses all dieser Rechnerei gespielt hat.

Nun nimmt er also jedes einzelne Gewicht—Hunderte Milliarden Gewichte—und fragt für jedes: „Wenn ich diese Zahl ein klein wenig größer oder kleiner gemacht hätte, wie viel mehr oder weniger Wahrscheinlichkeit wäre am Ende all dieser Rechnerei auf **n** entfallen?“

Das nennt man den **Gradienten** für diesen Parameter.ⁱ Der Gradient sagt, wie—und wie stark—man das Gewicht in diesem Parameter verändern muss, um die endgültige Antwort ein wenig richtiger zu machen.

Dann geht er hin und justiert jedes einzelne Gewicht entsprechend seinem Gradienten. Er schiebt jedes einzelne Gewicht in die Richtung, die die Antwort etwas richtiger macht. Nicht von Hand; er schreibt ein Programm, das es erledigt. KI-Ingenieure schauen sich nur selten auch nur eine der Zahlen an; es würde länger als ein Menschenleben dauern, sie alle anzusehen.

Informatiker stellen sich das als „Abstieg“ hin zu einer „weniger schlechten“ Antwort vor, daher „Gradientenabstieg“.

Dies einmal zu tun, ergibt keine perfekte Antwort, nur eine etwas weniger schlechte. Aber weil sich dieser gesamte Vorgang automatisieren lässt, kann er über Billionen von Wörtern—die sogenannten **Trainingsdaten**—hinweg wiederholt werden, in nur wenigen Monaten, für nur ein paar Hundert Millionen Dollar, auf den fortschrittlichsten Computern der Welt. (Hoffentlich ist unser Protagonist wohlhabend oder arbeitet für ein großes Unternehmen.) Diesen Vorgang nennt man **Training**.

7. Sobald die Maschine fertig trainiert ist, kann er die Ausgaben der Maschine—die Wahrscheinlichkeiten, die sie erzeugt—in ganz normalen Text verwandeln, den ein Nutzer sieht. Wenn die KI am stärksten **n** als Fortsetzung von **Es war einmal ei** vorhersagt, hängt er dieses **n** an und erhält **Es war einmal ein**. Dann speist er die neue, verlängerte Sequenz erneut ein, um eine Vorhersage des nächsten Buchstabens zu erhalten, und bekommt **e**. Er macht immer weiter, und die Maschine fängt an zu sprechen.

Diese Ansammlung von Hunderten Milliarden Gewichten, die per Gradientenabstieg immer wieder justiert werden, bis ihre wahrscheinlichsten Vorhersagen wie echte menschliche Sprache aussehen, nennt man ein großes Sprachmodell (engl. large language model, LLM). Genauer gesagt ein „Basismodell“.

Wenn er aus seinem Basismodell ein hilfreiches LLM wie ChatGPT machen will, gibt es noch einen Schritt: eine weitere Runde Gradientenabstieg mit Eingaben im Format:

Nutzer: Was ist die Hauptstadt von Spanien?

Assistent: Madrid.

Der Zweck dieses Teils ist nicht, dem LLM beizubringen, dass die Hauptstadt Spaniens Madrid ist; das weiß das LLM bereits, nachdem es mit einem großen Teil des Internets trainiert wurde. Vielmehr geht es darum, das LLM so abzustimmen, dass es den Text nach „Assistent:“ mit einer *hilfreichen Antwort* füllt und nicht mit einer Reaktion wie „Warum zum Teufel fragst du mich? Google es doch selbst“, egal wie verbreitet Letzteres in den echten menschlichen Gesprächen sein mag, mit denen es trainiert wurde. Wenn unser Ingenieur für einen großen Konzern arbeitete, der all diese Computer bereitstellte, ist dies auch die Phase, in der er der KI abtrainieren würde, zu fluchen oder darüber zu reden, wie man ein Auto kurzschließt—mithilfe menschlicher (oder neuerdings KI-generierter) Bewertungen darüber, welche Art von Antworten dem Konzern am angenehmsten sind.

Und daher kommen die Babys, metaphorisch gesprochen.